

Riconoscimento di Gesture tramite segnali EMG

Elias Ezequiel Moreno matricola n°244211

1. Definizione del Problema e Obiettivo

L'obiettivo di questo progetto è addestrare un modello di Deep Learning, valutandone le prestazioni nel riconoscimento dei gesti della mano.

Il compito che deve svolgere il modello è l'analisi di segnali elettromiografici, ricavati da sensori posti sull'avambraccio. La prima analisi si è svolta con un dataset ridotto, impostando così il problema come una più semplice **classificazione binaria**, dove vengono dati al modello solo due tipi di gesti da riconoscere: **Pugno** e **Mano a riposo**.

2. Composizione del Dataset e suddivisione dei dati

Il dataset proveniente dalla **UCI Machine Learning Repository** è composto da ben 36 cartelle, ciascuna rappresentante un individuo sottoposto alle misurazioni tramite sEMG. L'analisi è stata eseguita tramite un dispositivo con 8 sensori equidistanti che andranno a raccogliere segnali muscolari. Ad ogni partecipante è richiesto di svolgere due serie di 6/7 gesti svolti con la mano e mantenuti per 3 secondi, seguiti da una fase di riposo di 3 secondi. I risultati dei vari sensori vengono poi salvati in un file di testo composto da 10 colonne:

- **1° Colonna:** è la **marcatrice temporale**, ossia l'istante di tempo in cui viene svolta l'azione;
- **2°- 9° Colonna:** Queste sono i valori grezzi dei **segnali** rilevati dagli 8 sensori;
- **10° Colonna:** Questa rappresenta la **classe**, ossia l'azione svolta dal soggetto in quell'istante (*Ground Truth* che il modello userà per comprendere i gesti)

I valori della classe che si andranno ad analizzare saranno 2 (mano a pugno) e il 1 (mano a riposo), rimappate per il corretto funzionamento del modello rispettivamente come 0 ed 1. Un'analisi iniziale era di differenziare tra mano a pugno e mano aperta, questo compito però sarebbe risultato inconcludente a causa del forte sbilanciamento di dati tra le due classi, portando al modello a rispondere "mano a pugno" nella maggior parte dei casi, poiché la probabilità di trovare un caso di "mano aperta".

Approfittando della configurazione del dataset, si è optato per dividere gli individui usati per il *training* e quelli invece usati per il *testing* in modo da evitare in qualsiasi modo il **Data Leakage**. In particolare, i primi 24 soggetti saranno usati per allenare il modello mentre i restanti saranno usati per verificare l'allenamento di quest'ultimo. Questa configurazione permette di verificare il modello con pattern e segnali muscolari totalmente nuovi e mai visti durante la fase di training, verificandone perfettamente l'accuratezza.

2.1 Segmentazione dei segnali $\Rightarrow$ Windowing

Per poter utilizzare i valori grezzi dei sensori per allenare il modello di *Deep Learning* è necessario innanzitutto caricare i risultati attraverso una tecnica di segmentazione del segnale. Essa consiste nell'uso di una "finestra temporale" che scorre nel dataframe con passo di lunghezza inferiore alla grandezza di tale finestra, in modo da generare sovrapposizione tra due segmentazioni consecutive. In questo modo, si può garantire che si rilevi l'evoluzione nel tempo del segnale, mantenendo un elevato numero di campioni per l'addestramento.

Siccome alcune finestre temporali possono rilevare dati durante un periodo di transizione, dove il gesto passa da una configurazione all'altra, si definisce come gesto principale di ogni finestra, quello con il maggior numero di elementi all'interno di essa.

Frammento di codice dove si applica ciò che è stato definito anteriormente

```
for i in range(0, len(sensor_ds) - self.window_size, self.step_size):
    #Estrazione della finestra temporale per gli 8 canali
    window = sensor_ds[i : i + self.window_size]

    #Assegnazione del gesto principale per ogni finestra
    window_label = np.bincount(label_ds[i : i + self.window_size]).argmax()

    # Suddivisione per soggetti (Leave-Subjects-Out)
    if int(user_id) <= 24:
        x_train.append(window)
        y_train.append(window_label)
    else:
        x_test.append(window)
        y_test.append(window_label)
```

2.2 Normalizzazione dei tensori

Al fine di agevolare la convergenza dell'algoritmo durante la fase di addestramento del modello, è necessaria una normalizzazione dei valori grezzi ricavati dai sensori. I segnali da valutare

infatti, variano a seconda della forza impressa da ciascun individuo, per questo motivo non può essere un limite massimo e minimo come nel caso dei colori dei pixel (che vanno da 0 a 255). Date queste premesse si è optato per la normalizzazione di tali valori, calcolando media e deviazione standard del dataset, esclusa la parte dedicata alla valutazione. Questa decisione nasce per evitare che il modello abbia informazioni riguardanti il dataset di *testing*. Media e deviazione standard μ vengono successivamente applicati ad entrambi i dataset, aggiungendo a μ una costante $\epsilon = 10^{-8}$ per evitare casi in cui la deviazione standard sia pari a 0.

Codice:

```
def preprocess_data(x_train, x_test):
    # Calcolo media e deviazione standard del dataset per l'addestramento
    mean = np.mean(x_train, axis=(0,1), keepdims=True)
    std = np.std(x_train, axis=(0,1), keepdims=True)

    # Normalizzazione
    train_normalized = (x_train - mean) / (std + 1e-8)
    test_normalized = (x_test - mean) / (std + 1e-8)

    # Passaggio necessario per costruire i tensori
    train_tensor = torch.tensor(train_normalized, dtype=torch.float32)
    test_tensor = torch.tensor(test_normalized, dtype=torch.float32)

    # Trasposizione degli assi
    train_tensor = train_tensor.transpose(1, 2)
    test_tensor = test_tensor.transpose(1, 2)

    return train_tensor, test_tensor
```

La trasposizione è necessaria per adeguare il tensore alla forma richiesta dal modello [Batch, Input, window_size] anziché [Batch, window_size, Input].

3. Composizione modello

3.1 1° Modello $\Rightarrow$ Lenet1D

Il primo modello considerato è Lenet1D, che utilizza un'architettura CNN (*Convolutional Neural Network*) monodimensionale, ideale rispetto all'architettura bidimensionale data la struttura del nostro dataset. Questa rete neurale infatti, risulta ottima per l'analisi di pattern all'interno di dati sequenziali, come nel caso di segnali muscolari ricavati dall'EMG.

3.1.1 Struttura

Le rete neurale è strutturata su tre blocchi convoluzionali, seguiti da una classificazione lineare (*Fully connected*). Questa combinazione è scelta per permettere di estrarre i picchi dei segnali muscolari per ciascuno dei 8 valori di ingresso, mantenendo così le correlazioni temporali.

Ogni blocco convoluzionale è composto da 3 funzioni:

- **nn.Conv1d** applica i filtri convoluzionali ad una sequenza di dati definita come *kernel*, la quale lunghezza risulta pari a quella definita da *kernel_size*. *Stride* definisce il passo dopo il quale si studierà il seguente kernel. Il *padding* serve ad aggiungere una serie di zeri ai bordi del dataset per preservare le dimensioni del segnale originale.
- **nn.ReLU** è una funzione di attivazione la cui formula è $f(x) = \max(0, x)$. Lo scopo è introdurre non linearità, fondamentale nelle reti neurali per poter risolvere problemi complessi. Inoltre, grazie a essa, si elimina la possibilità di annullamento del gradiente (*Vanishing Gradient*). Questo fenomeno si presenta quando il valore dei gradienti raggiungono lo 0 durante la *backpropagation*, non permettendo quindi al modello di aggiornare i propri pesi, bloccando il *training*.
- **nn.MaxPool1d** svolge un sottocampionamento per ridurre la lunghezza del tensore considerato, riducendo i calcoli per i layer successivi e la sensibilità della rete neurale alle piccole variazioni temporali del segnale

nn.Linear è una funzione che rileva ogni *feature* estratta dalle convoluzioni precedenti e ne ricava un valore per ciascuna configurazione analizzata tramite l'equazione vettoriale $y = xA^T + b$, dove x è l'input, A sono i pesi contrassegnati e b è il termine di bias.

```
self.c1=nn.Conv1d(in_channels=8, out_channels=16, kernel_size= 5, stride= 1, padding= 2)
    self.r1 = nn.ReLU()
    self.p1 = nn.MaxPool1d(kernel_size=2, stride=2)

    #2° Blocco Convoluzionale
    #input [16, 100] -> dopo conv2 -> [32, 100] -> dopo il Pool -> [32, 50]
    self.c2=nn.Conv1d(in_channels=16, out_channels=32, kernel_size=5, stride=1, padding=2)
    self.r2=nn.ReLU()
    self.p2=nn.MaxPool1d(kernel_size=2, stride=2)

    #3° Blocco Convoluzionale
    #input -> [32, 50] -> dopo conv3 -> [128, 1]
    self.c3=nn.Conv1d(in_channels=32, out_channels=128, kernel_size=50, stride=1, padding=2)
    self.r3=nn.ReLU()
    self.fc1= nn.Linear(128, num_classes)
```

4. Training ed evaluation

Come già definito anteriormente, per garantire che l'addestramento dell'algoritmo non influenzi la valutazione di quest'ultimo, è stato deciso di separare i dati rispetto agli individui, così che la valutazione avvenisse con segnali mai osservati e evitare l'*overfitting* per contaminazione dei dati. Seguendo questa logica sono stati separati anche i due programmi di *training* e *testing* a scopo organizzativo, migliorando l'interpretabilità di quest'ultimi.

4.0.1 Composizione training

Questo programma svolge il *training loop* su una serie epoche. Il suo compito è alimentare l'algoritmo convoluzionale tramite i mini-batch, per poi calcolare la differenza tra le predizioni e la *ground truth*. Al fine di calcolare tale differenza, è stata scelta come *loss_function* la **Cross_Entropy_Loss**, poiché è la più adatta per i problemi di classificazione, aumentando il valore di *loss* in base alla gravità dell'errore di predizione. Successivamente, il valore di errore si propaga all'indietro, aggiornando il valore dei pesi tramite l'ottimizzatore **Adam**, il più popolare tra gli ottimizzatori dato che regola il *learning rate* in base ai gradienti di ciascun peso, migliorando la convergenza della predizione.

Al termine di ogni epoca, il codice stampa la loss media e l'accuratezza temporanea di addestramento, in modo da verificare ad ogni istante la convergenza ed eventuali anomalie nel processo di apprendimento.

Codice

```
for epoch in range(EPOCHS):
    epoch_start_time = time()
    model.train()
    #usiamo r_loss per calcolare l'errore per ogni epoca in modo da capire se l'errore diminuisce
    r_loss=0.0
    #usiamo correct_train e total_train per calcolare l'accuratezza del modello. Se l'accuratezza aumenta
    correct_train=0.0
    total_train=0.0

    for inputs, labels in train_loader:
        inputs, labels= inputs.to(device), labels.to(device)

        outputs = model(inputs)
        loss= loss_function(outputs, labels)

        optimizer.zero_grad()
        loss.backward()
```

```

optimizer.step()

r_loss += loss.item()

#a parte il calcolo della loss si aggiunge il calcolo dell'accuratezza per ogni epoca
_, predicted=torch.max(outputs.data, 1)
total_train+= labels.size(0)
correct_train+= (predicted==labels).sum()

```

Configurazione di **Batch_size** e **Learning_rate**

Durante il *training* del modello, è importante definire il valore delle variabili **Batch_size** e **Learning_rate**. Modificando il *batch_size*, possiamo variare la dimensione del tensore dei gradienti: se esso risulta troppo piccolo, l'addestramento diventa più lento, mentre se il valore è troppo alto, la dimensione del tensore diventa troppo grande per essere contenuto all'interno della VRAM, portando il codice in crash (Cuda Out of Memory).

Modificando il *learning_rate*, si varia la velocità di variazione dei pesi dell'ottimizzatore. Se il valore è troppo piccolo, il modello impiegherà molto tempo per ridurre l'errore minimo, mentre se il valore è troppo alto, la *loss* diverge, non raggiungendo mai un valore di errore soddisfacente.

4.0.2 Composizione *testing*

Questo programma carica i pesi ottimali precedentemente ottenuti dal *training* e successivamente salvati all'interno del file *emg_lenet1d.pth* per poi procedere con la valutazione del modello tramite la funzione `model.eval()`, accompagnata da `torch.no_grad()` affinché l'algoritmo non calcoli il gradiente dei tensori, non utilizzati durante la valutazione. Una volta completata la valutazione, il programma procede a stampare a schermo il risultato di accuratezza finale, da cui poi si concluderà se il modello è affidabile.

Codice

```

with torch.no_grad():
    correct = 0
    total = 0

    # Ciclo sui dati del Test Set (gli utenti rimasti fuori dall'addestramento)
    for inputs, labels in test_loader:
        inputs, labels = inputs.to(device), labels.to(device)

```

```

# Passaggio in avanti
outputs = model(inputs)

# Troviamo il gesto con il punteggio più alto (0 o 1)
_, predicted = torch.max(outputs.data, 1)

# Accumuliamo il totale delle finestre e quelle indovinate
total += labels.size(0)
correct += (predicted == labels).sum().item()

```

4.1 Considerazioni sui risultati

4.1.1 Classificazione binaria tramite lenet1D

Analizzando i tempi di addestramento e l'accuratezza per ciascuna epoca, si può notare come la durata della prima epoca, nonché la sua accuratezza, sono drasticamente diverse rispetto alle restanti. Questo comportamento irregolare è dovuto principalmente ad operazioni all'**allocazione della memoria (RAM/VRAM)**, dove Pytorch richiede l'assegnazione di blocchi di memoria contigui all'interno della VRAM della GPU nel quale saranno caricati i tensori dei batch e i pesi dell'ottimizzatore. Questa esecuzione non avviene per ogni epoca, ma solo durante la prima richiesta, dopo la quale si andranno ad aggiornare gli stessi blocchi.

Epoch [1/15],	Loss: 0.2668,	Acc: 90.3335,	elapsed time: 0.3706 seconds
Epoch [2/15],	Loss: 0.0781,	Acc: 97.7764,	elapsed time: 0.1208 seconds
Epoch [3/15],	Loss: 0.0462,	Acc: 98.5794,	elapsed time: 0.1123 seconds
Epoch [4/15],	Loss: 0.0322,	Acc: 99.0117,	elapsed time: 0.1161 seconds
Epoch [5/15],	Loss: 0.0249,	Acc: 99.2279,	elapsed time: 0.1059 seconds
Epoch [6/15],	Loss: 0.0162,	Acc: 99.3823,	elapsed time: 0.1107 seconds
Epoch [7/15],	Loss: 0.0105,	Acc: 99.6603,	elapsed time: 0.1110 seconds
Epoch [8/15],	Loss: 0.0092,	Acc: 99.7529,	elapsed time: 0.1097 seconds
Epoch [9/15],	Loss: 0.0065,	Acc: 99.8147,	elapsed time: 0.1135 seconds
Epoch [10/15],	Loss: 0.0035,	Acc: 99.9691,	elapsed time: 0.1083 seconds
Epoch [11/15],	Loss: 0.0026,	Acc: 99.9691,	elapsed time: 0.1045 seconds
Epoch [12/15],	Loss: 0.0027,	Acc: 99.9691,	elapsed time: 0.1104 seconds
Epoch [13/15],	Loss: 0.0019,	Acc: 99.9691,	elapsed time: 0.1058 seconds
Epoch [14/15],	Loss: 0.0015,	Acc: 100.0000,	elapsed time: 0.1223 seconds
Epoch [15/15],	Loss: 0.0011,	Acc: 100.0000,	elapsed time: 0.1056 seconds

Dopo aver concluso la valutazione, LeNet-1D ha raggiunto un'accuratezza finale di 97%. Si può affermare che questo risultato non è dovuto a *Data Leakage* grazie a tutte le decisioni riguardanti l'isolamento dei dataset. Inoltre, da un risultato così elevato, si conclude che il

numero di epoche selezionato è attorno al valore ideale, poiché il modello non è andato in *overfitting*.